

Distribución Binomial

Trabajo Práctico

Asignatura: Analítica de datos

Estudiante: Juliana Hernández

Fecha: 18 de septiembre de 2026

Universidad Católica del Uruguay

Campus Punta del Este

Resumen

En el presente informe se analiza la ocurrencia de paquetes dañados mediante la distribución binomial y su aproximación mediante la distribución normal. Para ello, se trabajó en Google Colab con dos bases de datos correspondientes a lotes de 50 y 2000 paquetes. En ambos casos se determinó una proporción de paquetes dañados del 2 %, utilizada como probabilidad de daño en el modelo binomial. Se analizaron las distribuciones correspondientes a ambos tamaños de lote y se calcularon diferentes probabilidades. Para el lote de 50 paquetes se obtuvo una probabilidad de 0,1858 de que exactamente 2 paquetes estuvieran dañados y de 0,2642 de que hubiera 2 o más paquetes dañados. Para el lote de 2000 paquetes se aplicó la aproximación normal, obteniendo una media de 40 y una desviación estándar aproximada de 6,26. Mediante la corrección por continuidad se obtuvo una probabilidad aproximada de 0,0178 de que exactamente 30 paquetes estuvieran dañados, mientras que el cálculo exacto mediante la distribución binomial dio como resultado 0,0181. De esta manera, se compararon los resultados obtenidos mediante ambos métodos y se analizó la utilidad de la aproximación normal para tamaños de muestra grandes.

Índice

1. Introducción	3
2. Desarrollo	3
2.1. Carga, Verificación y Forma de las Bases de Datos	3
2.2. Análisis Descriptivo	4
2.3. Determinación de la Probabilidad de Daño	4
2.4. Distribución Binomial	5
2.5. Gráficos de la Distribución Binomial	5
2.6. Cálculos de Probabilidades	5
2.6.1. Lote de 50 paquetes	8
2.6.2. Lote de 2000 paquetes y aproximación normal	8
3. Conclusión	9
4. Referencias	10

1. Introducción

En el análisis estadístico de procesos industriales y logísticos, es frecuente estudiar la ocurrencia de eventos específicos, como la presencia de piezas defectuosas o paquetes dañados. Cuando estos eventos pueden clasificarse en dos resultados posibles, como “dañado” o “no dañado”, y se consideran una cantidad determinada de ensayos independientes con una probabilidad constante de ocurrencia, la distribución binomial constituye un modelo adecuado para representar este tipo de situaciones [3].

La distribución binomial permite calcular la probabilidad de obtener una determinada cantidad de éxitos en un número fijo de ensayos independientes, cuando la probabilidad de éxito se mantiene constante. Sin embargo, cuando el número de ensayos es suficientemente grande, bajo determinadas condiciones, la distribución binomial puede aproximarse mediante una distribución normal. Esta aproximación permite simplificar determinados cálculos probabilísticos [3].

El objetivo de este informe es aplicar estos conceptos mediante un script desarrollado en Google Colab [2], utilizando dos bases de datos correspondientes a lotes de diferentes tamaños. A lo largo del documento se detalla la carga y verificación de los datos, el análisis descriptivo, el cálculo de la proporción de paquetes dañados, la representación gráfica de las distribuciones binomiales y el cálculo de probabilidades mediante la distribución binomial y la aproximación normal.

2. Desarrollo

El análisis se llevó a cabo empleando un entorno de programación en Python mediante Google Colab, utilizando librerías como `pandas`, `numpy`, `matplotlib` y `scipy.stats`. El trabajo consistió en procesar dos bases de datos con información sobre paquetes y su estado de daño, con el objetivo de analizar probabilísticamente la cantidad de paquetes dañados.

2.1. Carga, Verificación y Forma de las Bases de Datos

En primer lugar, se importaron dos archivos de Excel correspondientes a diferentes tamaños de lotes:

- **Base de Datos 1 ($df1$):** cuenta con dimensiones de 50 filas y 2 columnas, correspondientes al número de paquete y su estado de daño. Representa un lote de 50 paquetes.
- **Base de Datos 2 ($df2$):** cuenta con dimensiones de 2000 filas y 2 columnas, correspondientes al número de paquete y su estado de daño. Representa un lote de 2000 paquetes.

La primera base contiene 50 observaciones, mientras que la segunda contiene 2000. Estas dimensiones fueron verificadas mediante la función `shape` [1].

A continuación, la Tabla 1 muestra los primeros registros de la base de datos pequeña (`df1`), obtenidos mediante `df1.head()`:

Asimismo, la Tabla 2 muestra los primeros registros del lote grande (`df2`):

2.2. Análisis Descriptivo

Como parte del análisis inicial de los datos, se utilizó la función `describe()` para obtener medidas descriptivas de las variables presentes en ambas bases de datos.

En la base correspondiente a los 50 paquetes, la variable `dañado` presentó una media de 0,02 y una desviación estándar de aproximadamente 0,1414. El valor mínimo fue 0 y el máximo fue 1, lo que refleja que la variable se encuentra codificada de forma binaria para indicar si un paquete se encuentra dañado o no [1].

En la base correspondiente a los 2000 paquetes, la variable `dañado` presentó nuevamente una media de 0,02, con una desviación estándar aproximada de 0,1400. Al igual que en la primera base, los valores mínimo y máximo fueron 0 y 1, respectivamente [1].

La media de 0,02 de la variable `dañado` permite interpretar que la proporción de paquetes dañados es del 2 % en ambos conjuntos de datos. Esta proporción será utilizada posteriormente como valor de la probabilidad de daño en el modelo binomial.

2.3. Determinación de la Probabilidad de Daño

A partir de la columna `dañado`, se contó la cantidad de paquetes que presentaban daño y se calculó su proporción respecto del total de paquetes.

Para la primera base se obtuvo:

$$p_1 = \frac{1}{50} = 0,02$$

Por lo tanto, el porcentaje de paquetes dañados en el lote de 50 fue del 2 % [1].

Para la segunda base se obtuvo:

$$p_2 = \frac{40}{2000} = 0,02$$

Por lo tanto, el porcentaje de paquetes dañados en el lote de 2000 también fue del 2 % [1].

En consecuencia, para el análisis de las distribuciones binomiales se utilizó:

$$p = 0,02$$

como probabilidad de que un paquete resulte dañado.

2.4. Distribución Binomial

La distribución binomial permite modelar el número de paquetes dañados en un lote cuando se considera que cada paquete representa un ensayo con dos posibles resultados: dañado o no dañado [3].

Su función de probabilidad se expresa como:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

donde:

- n representa el número total de paquetes.
- k representa el número de paquetes dañados.
- p representa la probabilidad de que un paquete resulte dañado.

La función de probabilidad y sus parámetros corresponden a la definición de la distribución binomial utilizada en el material de la asignatura [3].

En el análisis se utilizó la función `stats.binom.pmf()` para obtener las probabilidades correspondientes a cada cantidad posible de paquetes dañados [4].

2.5. Gráficos de la Distribución Binomial

Para observar el comportamiento de las distribuciones, se calcularon las probabilidades binomiales para ambos tamaños de lote y se representaron mediante diagramas de barras.

- **Distribución Binomial para $n = 50$:** representa las probabilidades correspondientes a las diferentes cantidades posibles de paquetes dañados en un lote de 50, utilizando una probabilidad de daño de $p = 0,02$.
- **Distribución Binomial para $n = 2000$:** representa las probabilidades correspondientes a las diferentes cantidades posibles de paquetes dañados en un lote de 2000, utilizando también $p = 0,02$. En este caso, la distribución presenta una forma que puede aproximarse a una distribución normal debido al mayor tamaño del lote.

El código utiliza `stats.binom.pmf()` para calcular las probabilidades y limita el segundo gráfico al intervalo de 0 a 60 paquetes dañados para facilitar su visualización [4].


2.6. Cálculos de Probabilidades

Se realizaron diferentes cálculos probabilísticos utilizando la distribución binomial y, para el lote de 2000 paquetes, la aproximación mediante la distribución normal.

Paquete	Dañado
1	0
2	0
3	0
4	0
5	0

Cuadro 1: Primeros registros del lote de 50 paquetes ($df1$).

Paquete	Dañado
1	1
2	1
3	1
4	1
5	1

Cuadro 2: Primeros registros del lote de 2000 paquetes ($df2$).Figura 1: Distribución binomial para $n = 50$ y $p = 0,02$.




Figura 2: Distribución binomial para $n = 2000$ y $p = 0,02$.

2.6.1. Lote de 50 paquetes

Para un lote de 50 paquetes, con $p = 0,02$, se calculó la probabilidad de que exactamente 2 paquetes estuvieran dañados mediante:

$$P(X = 2) = 0,1858$$

El resultado obtenido mediante `stats.binom.pmf()` fue de 0,1858, equivalente a aproximadamente un 18,58 % [4].

También se calculó la probabilidad de que hubiera 2 o más paquetes dañados. Para ello se utilizó el complemento de la probabilidad acumulada hasta 1:

$$P(X \geq 2) = 1 - P(X \leq 1)$$

El resultado obtenido fue:

$$P(X \geq 2) = 0,2642$$

equivalente a aproximadamente un 26,42 %.

2.6.2. Lote de 2000 paquetes y aproximación normal

Para el lote de 2000 paquetes se utilizó la aproximación de la distribución binomial mediante una distribución normal [3].

La media se calculó como:

$$\mu = np$$

Por lo tanto:

$$\mu = 2000(0,02) = 40$$

La desviación estándar se calculó mediante:

$$\sigma = \sqrt{np(1-p)}$$

obteniéndose:

$$\sigma = \sqrt{2000(0,02)(0,98)} \approx 6,261$$

Estos son los valores utilizados en el Colab para realizar la aproximación normal.

Para calcular la probabilidad de que exactamente 30 paquetes estuvieran dañados mediante la distribución normal, se utilizó la **corrección por continuidad**. En lugar de considerar únicamente el valor 30, se tomó el intervalo:

$$29,5 < X < 30,5$$

De esta forma, se calculó:

$$P(29,5 < X < 30,5)$$

obteniéndose:

$$P(X = 30) \approx 0,0178$$

mediante la aproximación normal [3, 4].

Finalmente, se calculó la misma probabilidad directamente mediante la distribución binomial, sin utilizar la aproximación normal:

$$P(X = 30) = 0,0181$$

Este valor fue obtenido mediante el cálculo exacto con `stats.binom.pmf()` [4].

La comparación entre ambos resultados muestra que la aproximación normal produjo un valor de 0,0178, mientras que el cálculo exacto mediante la distribución binomial produjo 0,0181.

3. Conclusión

A lo largo de este informe se analizó el comportamiento de una variable discreta mediante la distribución binomial y su aproximación mediante la distribución normal para un tamaño de lote mayor.

A partir de las dos bases de datos analizadas, correspondientes a lotes de 50 y 2000 paquetes, se obtuvo una proporción de paquetes dañados del 2% en ambos casos. Esta proporción fue utilizada como probabilidad de daño en el modelo binomial.

Para el lote de 50 paquetes se calcularon probabilidades mediante la distribución binomial, obteniéndose una probabilidad de 0,1858 de que exactamente 2 paquetes estuvieran dañados y una probabilidad de 0,2642 de que hubiera 2 o más paquetes dañados.

Para el lote de 2000 paquetes se aplicó la aproximación normal. Se obtuvo una media de 40 y una desviación estándar aproximada de 6,26. Utilizando la corrección por continuidad, la probabilidad aproximada de que exactamente 30 paquetes estuvieran dañados fue de 0,0178. Al realizar el cálculo exacto mediante la distribución binomial, se obtuvo 0,0181.

La comparación de estos resultados permitió observar cómo la distribución normal puede utilizarse como una aproximación de la distribución binomial en determinados escenarios con un número elevado de ensayos. Asimismo, el ejercicio permitió aplicar herramientas de Python y `scipy.stats` para realizar cálculos probabilísticos y representar

gráficamente el comportamiento de las distribuciones.

4. Referencias

Referencias

- [1] Datos de la Asignatura. *Bases de datos de paquetes (Lotes de 50 y 2000 registros en XLSX)*. Disponible en Google Drive de la Asignatura: https://drive.google.com/drive/folders/1ajXu1G8PJvAEu0ZWYZQEsRGviYHzdC0n?usp=share_link
- [2] Google. *Google Colaboratory (Colab): Entorno de desarrollo en la nube para Python*. Disponible en: <https://colab.research.google.com/>
- [3] Profesor de la Asignatura. *Notebooks y pautas de la Tarea 3: Distribución Binomial y Normal en Google Colab*. Material de la asignatura de Analítica de Datos.
- [4] SciPy Community. *SciPy Stats documentation: Binomial and Normal distributions (`scipy.stats.binom` / `norm`)*. Disponible en: <https://docs.scipy.org/>